University of St.Gallen

# Eduatar – the legal chatbot

Spring Semester
St.Gallen, 25th May 2023

**Group A**

Kaan Aydin
Sven Schnydrig

From insight to impact.

# Project Approach

University of St.Gallen

## Generate dataset of Q&A pairs

- *Factsheets*
- *Partner Data*

## Set up pipeline & fine-tune

- *BERT*
- *GPT3.5/4*
- *Vicuna*

## Evaluation of models & pipelines

- *Manual*
- *GPT4 Evaluation*

# Project approach | Generate dataset of Q&A pairs

## Data collection

Overall, we used two primary sources:

**1st source:** Fact sheets & legal docs manually downloaded from «Berufsbildung»

**2nd source:** Collection of previous Q&As provided by our partner

## Preparation of input to ChatGPT

First, we extracted (relevant) paragraphs from our data

Then, we developed a prompt that did well in generating Q&A pairs and appended to each paragraph

## ChatGPT query & Q&A generation

We queried all paragraphs / prompts in ChatGPT Q&A pairs and saved them in a separate file

Overall, we created a dataset of ~500 Q&A pairs

## Reasons for building a Q&A dataset

Fine-tuning of BERT and Vicuna (tbd) requires Q&A pairs (with context)

Perfomance evaluation of pipelines (more details later)

# Project approach | Set up pipeline & fine-tune

| | GELECTRA | GPT | VICUNA |
|---|---|---|---|
| **Description** | • Pre-trained BERT-based German language model & finetuned w/ GermanQuAD | • We use the OpenAIs GPT 3.5/4 as it is shown to be most effective | • LLM based on LLaMa & finetuned on human convos – results close to GPT4 |
| **Details on Pipeline setup** | • HuggingFace to download pre-trained Gelectra<br>• Haystack for the reader-retriever pipeline | • OpenAI's API access to deploy GPT 3.5/4 model<br>• Use of LangChain for pipeline setup, incl. memory buffering | • Download weights and run model with GPU in Colab Pro<br>• Potential use of LangChain for memory buffering |
| **Considerations** *(i.e., advantages / disadvantages)* | • Smaller model, not built for Chatbots<br>• Poor results, requires more fine-tuning with limited upside | • Works very well as more chatbot like functionality<br>• Rather costly | • Good performance despite being smaller model<br>• Cheaper vs. GPT, but requires own GPU setup to deploy |

# Preliminary results

| | Q1: Ist es möglich, Lernenden wegen Krankheitstagen die Ferienzeit zu kürzen? | Q2: Wie lange darf man bei der Arbeit Pausen machen? |
|---|---|---|
| **Gelectra** | **A:** Ist nicht möglich<br>**C:** ist nicht möglich, da die Ferien zu Erholungszwecken dienen und nicht „verrechnet“ werden dürfen. | **A:** um die Mitte der Arbeitszeit<br>**C:** die gleichen Pausen wie für Erwachsene: Die Arbeit muss um die Mitte der Arbeitszeit durch Pausen von folgender Mindestdauer unterbrochen werde. |
| **GPT 3.5** | **A:** Nein, es ist nicht möglich, Lernenden wegen Krankheitstagen die Ferienzeit zu kürzen. Im GAV der Polymechaniker sind bei Krankheit zwei Karenztage vorgesehen. Das heißt, die ersten zwei Krankheitstage werden nicht bezahlt. Ein Ferienabzug darf nicht erfolgen. | **A:** Laut Arbeitsgesetz muss eine Pause von mindestens einer halben Stunde nach 9 Stunden Arbeit gewährt werden. Am Samstag muss nach spätestens 51/2 Stunden eine Pause von einer Viertelstunde gewährt werden. |